

Conceptos de Machine Learnig

Francisco J. Ribadas-Pena

28 de abril de 2021

Grupo CoLe – 2021

Aprendizaje automático

Elementos básicos

Tipos de Aprendizaje Automático

Tareas/aplicaciones típicas

Evaluación

Aprendizaje automático

Definición

APRENDIZAJE: *“Proceso mediante el cual un sistema mejora su rendimiento en una tarea determinada en base a una experiencia.”*

En todo sistema de aprendizaje automático será necesario definir y modelizar:

- Cúal es la tarea a mejorar
- De qué experiencia se dispone
- Cómo se mide el rendimiento

Aprendizaje automático/Machine Learning (II)

Ejemplos

Tarea	Experiencia	Medida rendimiento
jugar a las damas	jugar contra uno mismo	% partidas ganadas
reconocim. texto manuscrito	muestra textos clasificados	n. letras errneas
diagnóstico médico	conj. sintomas+diagnostico	% diagnósticos correctos

En el diseño de un sistema que "aprenda" se debe elegir:

- Lo que se va aprender (**hipótesis/concepto objetivo**)
- **Lenguaje de representación** de la hipótesis objetivo
- **Experiencia** a usar en el aprendizaje (y cómo y dónde obtenerla)
- **Algoritmo** para aprender la hipótesis objetivo a partir de esa experiencia

Aprendizaje automático/Machine Learning (III)

Utilidad

Sistemas demasiado difíciles o imposibles de construir de forma manual

- Entornos que requieran conocimiento muy específico y detallado (no disponible)
- Ej.: problemas de percepción (reconocer caracteres manuscritos, reconocim. de voz, , conducir coche, ...)

Sistemas que puedan adaptarse y modificarse por sí mismos

- Sistemas capaces de actuar en entornos cambiante o nuevos
- Ej.: sistemas que se adapten a las necesidades de un usuario (asistentes personales, filtros web, conducir coche, etc...)

Descubrimiento de conocimiento en grandes bancos de datos

- Técnicas de *Data mining*
- Ej.: identificación de patrones de compra

Modelos computacionales del aprendizaje biológico y del conocimiento humano

Áreas relacionadas

1. Inteligencia Artificial
 - Representación conocimiento
 - Aprendizaje como problema de búsqueda,
2. Matemáticas
 - Estadística (teorema de Bayes, técnicas de estimación, contraste de hipótesis, ...)
 - Lógica (formalismos representación y razonamiento)
3. Psicología: modelos del razonamiento humano
4. Biología: Neurobiología (modelos del cerebro y neuronas)
5. Otras: Teoría de la información (entropía y contenido de información), ...

Elementos básicos

CONCEPTOS o HIPÓTESIS o MODELOS

Tipos de “cosas” que pueden ser aprendidas

- Salida de algoritmo de aprendizaje: descripción/representación del concepto/hipótesis aprendido
- En la mayoría de los casos, se puede modelar como una función $c(e)$ que ofrece una salida para un ejemplo e .
- El algoritmo de aprendizaje debe encontrar/generar una hipótesis h , que haga $h(e) = c(e)$ para los ejemplos de entrenamiento.

OBJETIVO: El algoritmo de aprendizaje debe ser capaz de generalizar y crear una hipótesis h que sea “*suficientemente*” correcta para ejemplos distintos a los del conjunto de entrenamiento. ($h(e) \approx c(e)$)

REPRESENTACIÓN DE HIPÓTESIS

Múltiples posibilidades para representar las hipótesis que maneja y aprende el sistema de aprendizaje

Ejemplos: {
árboles de decisión
reglas de producción
lógica de predicados
 k vecinos más próximos y función de proximidad
pesos de conexiones en redes neuronales
secuencias de "genes"

Tipo de representación condicional: {
qué se puede aprender
cómo se realiza ese aprendizaje

En general, podrá modelizarse el aprendizaje como una búsqueda de las hipótesis que mejor se adapten a los datos de entrenamiento.

EJEMPLOS/INSTANCIAS

Elementos de entrada al sistema de aprendizaje

- Casos individuales e independientes del concepto objetivo.
- Elementos sobre los que se aprende a clasificar, asociar, agrupar, predecir, etc..
- Caracterizados por un conjunto predeterminado de atributos.
- En tareas de clasificación: atributo especial **clase** (objetivo del aprendizaje)

En aprendizaje supervisado : incluyen indicación de la salida correcta

- Si el resultado es booleano (o discreto)
 - Ejemplos **positivos**: son *verdaderos* (pertenecen a la clase)
 - Ejemplos **negativos**: son *falsos* (no pertenecen a la clase)

Entrada al algoritmo de aprendizaje: conjunto de ejemplos (*dataset*)

ATRIBUTOS/CARACTERÍSTICAS/FEATURES

Características de interés que describen un ejemplo.

- Problemas: $\left\{ \begin{array}{l} \text{Dependencias entre atributos} \\ \text{Atributos irrelevantes} \\ \text{Valores desconocidos o incorrectos} \end{array} \right.$

Tipos de atributos:

- **Nominales:** los valores de los atributos son etiquetas,
 - No es posible definir ordenación ni distancia en los atributos
 - Sólo operaciones de igualdad
 - Ej.: culpable/inocente, gripe/ébola/bronquitis/...
- **Ordinales:** valores nominales o numéricos
 - Existe una relación de orden entre los valores
 - No posible definir distancia
 - Ej.: enero/febrero/..., susp./aprob./notable/..., 0/5/7.5/9/10
- **Numéricos:** valores numéricos
 - Posible definir orden y distancia

Tipos de Aprendizaje Automático

En función de cómo sea la experiencia que se utiliza durante el entrenamiento

1. Aprendizaje supervisado
2. Aprendizaje no supervisado
3. Aprendizaje semisupervisado

APRENDIZAJE SUPERVISADO

Algoritmo de aprendizaje tiene información del resultado asociado a cada ejemplo.

- Conoce el ejemplo e y el resultado correcto de $h(e)$

Existe un “maestro” que indica lo que es correcto y lo que no

1. conocido **a priori**: disponible antes de iniciar entrenamiento
 - típico en problemas de clasificación o regresión
2. conocido **durante aprendizaje**: existe un mecanismo (de premio/castigo) que informa de la bondad del resultado obtenido
 - mezcla aprendizaje y actuación, aprende cómo maximizar recompensas
 - usado en **aprendizaje por refuerzo**

APRENDIZAJE NO SUPERVISADO

Algoritmo no tiene acceso a información sobre el resultado esperado

- Sólo se conocen los ejemplos, no sus resultados
- *Ejemplo:* problemas de clustering (clasificación sin clases predefinidas)

Algoritmos buscan identificar regularidades en el conjunto de ejemplos

APRENDIZAJE SEMISUPERVISADO

Parte de los ejemplos de entrenamiento están anotados y otra parte no

- Active Learning → el algoritmo de aprendizaje selecciona qué ejemplos le interesa que sean anotados por el "maestro" externo
 - normalmente los ejemplos que delimitan las regiones de decisión

APRENDIZAJE POR REFUERZO

(tipo particular de aprend. supervisado)

Aprendizaje propio de agentes autónomos que aprenden a elegir las acciones óptimas para sus objetivos en función del resultado de sus acciones.

- Ante cada acción del sistema un entrenador externo premia o castiga su acción
- Sistema aprende a generar secuencias de acciones que provean mayores recompensas.
- *ejemplo*: robot corrige trayectoria (a golpes)

Tareas/aplicaciones típicas

APRENDIZAJE DE CLASIFICACIONES

Asignación de un ejemplo a una o más clases o categorías

Aprendizaje supervisado: cada ejemplo es acompañado de la clase a la que pertenece

- Evaluación: usando nuevos ejemplos "no vistos" cuya clase sea conocida

Tipos de clasificación:

binaria única salida binaria (valores $\{0, 1\}$, $\{-1, +1\}$)

Ejemplo: análisis de sentimiento en textos : {favorable, desfavorable}

multiclase (multiclass) única salida discreta con n valores posibles

Ejemplo: reconocimiento de entidades en texto: {personas, organizaciones, lugares, fechas}

multietiqueta (multilabel) múltiples salidas, normalmente multiclase, no necesariamente disjuntas

Ejemplo: caracterización de personas en fotos $\left\{ \begin{array}{l} \text{sexo:}\{\text{maculino, femenino, otro}\} \\ \text{edad:}\{\text{joven, adulto, anciano}\} \\ \text{origen:}\{\text{asiático, africano, ...}\} \end{array} \right.$

PREDICCIÓN NUMÉRICA/REGRESIÓN

Predecir una cantidad numérica en función de los atributos del ejemplo

- Similar a clasificación (con salida numérica y continua)
- Aprendizaje supervisado
- *Ejemplos:* predicción de ingresos, valores bursátiles, etc...

APRENDIZAJE DE ASOCIACIONES

Detectar asociaciones entre distintas características de los datos de entrenamiento.

- Generalización del problema de la clasificación:
 - Se predice sobre cualquier valor de atributo
 - Puede predecirse más de un valor
- Necesidad de definir restricciones (muchas reglas posibles)
 - Maximizar/minimizar cobertura y/o exactitud
- *Ejemplos:* Asociaciones entre productos en las compras de clientes

CLUSTERING (Agrupamiento)

Identificación de grupos de ejemplos similares.

- Se busca maximizar la similitud dentro del grupo y minimizarla con respecto a elementos de otros grupos.
- Aprendizaje no supervisado: la clase (\approx grupo) de cada ejemplo es desconocida
- *Ejemplos:* $\left\{ \begin{array}{l} \text{identificación de perfiles/prototipos de clientes} \\ \text{agrupamiento de documentos por temática similar} \end{array} \right.$

OTROS

- Detección de anomalías
 - Identificación de ejemplos "fuera de lo normal" (supervisado/no supervisado)
 - *Ejemplo*: detección de intrusiones en red
- Modelado de tópicos (*topic modeling*)
 - Identificación de grupos de documentos similares y caracterización de las temáticas (*word lists*) de esos grupos
 - Caso particular de *clustering* textual (no supervisado)

Evaluación

Datasets de evaluación

train : dataset usado para entregar/construir modelo/hipótesis

dev (opcional): usado durante el desarrollo para evaluar el rendimiento del modelo/hipótesis

- ajuste de parámetros del algoritmo de aprendizaje
(*hyperparameter tuning*)

test : usado para evaluar el rendimiento del modelo/hipótesis "final" sobre **ejemplos no vistos** en el aprendizaje

Matriz de confusión (clasificación binaria)

Valor Predicho	Valor Real	
	Positivo	Negativo
Positivo	TP	FP
Negativo	FN	TN

Métricas

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN}$$

$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

$$F1score = 2 \frac{(Recall \cdot Precision)}{(Recall + Precision)}$$

Validación cruzada (*cross validation*): busca garantizar que la evaluación no dependa de una partición concreta de train y test

- Dataset dividido en k subconjuntos (*k-fold cross validation*)
- En cada iteración (hasta k) se entrena con $k - 1$ subconjuntos y se valida con el restante
- Media aritmética de los k resultados parciales de las métricas empleadas

Proporciona métricas de rendimiento más robustas

Evaluación (III)

Sobreajuste (overfitting, sobreadaptación, sobreentrenamiento)

Existe **sobreajuste** de una hipótesis/modelo h ante un conjunto de datos de entrenamiento cuando

1. existe otra hipótesis/modelo h' cuyo error en el **conj. de entrenamiento** es mayor que el de h
2. el error de h' sobre el **conj. de validación** es menor que el de h

Consecuencia: la hipótesis/modelo h no es capaz de generalizar

- Ha "memorizado" los ejemplos del conj. de entrenamiento → obtiene buen rendimiento con esos datos
- Su rendimiento al predecir ejemplos nunca vistos del conj. de validación es peor

Típico en algoritmos que generan modelos/hipótesis muy complejos (con muchos parámetros)

- *Ejemplo:* árboles de decisión con muchas ramas, redes neuronales con muchas capas/nodos, etc
- También algoritmos de aprendizaje que ajustan sus hipótesis/modelos iterativamente → memorizan conj. entrenamiento al realizar demasiadas iteraciones